

招贝

# AI 能力设计说明书

数据与模型方案 v2.0

先帮你管住焦虑，再帮你管好钱

招商银行 | 2026 年 5 月 | V2.0

# 目录

- 1 AI 定位与设计原则 .....1
- 2 AI 不可替代性分析 .....5
- 3 AI 任务拆解 ..... 8
- 4 数据来源与数据契约 ..... 12
- 5 标签体系与分类标准 ..... 13
- 6 训练数据建设方案 ..... 14
- 7 模型架构与选型 ..... 15
- 8 微调与训练流程 ..... 16
- 9 RAG 知识库与 AI 顾问 .....17
- 10 评估指标与上线门槛 .....18
- 11 反馈闭环与持续迭代 .....19
- 12 安全、合规与中立性护栏 .....20
- 13 版本路线图与开放问题 .....21

# 1 AI 定位与设计原则

**核心定位变更：用户不是来问问题的，是来授权 AI 执行规划的。**

本产品的 AI 不应被理解为"高级聊天框"或"智能客服"。用户复制账单去 ChatGPT 也能得到分析，但招贝的 AI 是基于用户私有数据、银行 API、持续反馈闭环的自动化财务决策中枢。AI 的输出不是文字回答，而是可直接执行的结构化决策方案。

|            |                                        |
|------------|----------------------------------------|
| 旧定位 (v1.0) | AI 亲子顾问 = 高级聊天框，回答用户问题                 |
| 新定位 (v2.0) | AI 亲子财务决策中枢 = 基于私有数据的自动化规划引擎，输出结构化决策方案 |
| 核心差异       | 从"问答"升级为"授权执行"；从"文字回答"升级为"结构化决策方案"     |
| 用户行为       | 不是来"问问题"，而是来"授权 AI 执行规划"               |
| 关键原则       | 数据优先、可解释优先、低置信追问、宁可漏报不乱报、规划而非投顾、中立性    |

## 1.1 核心定位：自动化财务决策中枢

招贝 AI 的核心定位是"基于私有数据的自动化财务决策中枢"。这一定位包含三层含义：

- 自动化：AI 不仅给出建议，而是直接生成预算重分配草案、触发招行定投计划、预约顾问——从"建议"到"执行"的完整闭环。
- 基于私有数据：批量 OCR+银行 API+课程合同结构化解析，形成用户独有的数据资产，ChatGPT 无法复制。
- 决策中枢：AI 亲子顾问从最后一项提升为核心整合层，所有任务围绕"结构化决策方案"输出，而非分散的问答。

1.2 设计原则

| 原则       | 说明                                          |
|----------|---------------------------------------------|
| 数据优先     | AI 分类必须基于用户授权数据、交易/OCR/手动录入、家庭画像，而不是仅凭大模型常识 |
| 可解释优先    | 所有焦虑/风险提醒必须输出识别依据、置信度、可纠错入口                 |
| 低置信追问    | 信息不足时不强判，触发追问或人工复核                          |
| 宁可漏报，不乱报 | MVP 阶段焦虑识别优先 Precision，避免误伤用户信任             |
| 规划而非投顾   | AI 提供预算、目标、风险和选择框架，不输出具体证券/基金买卖建议           |
| 中立性      | AI 建议基于家庭目标和风险匹配，不以产品佣金或本行产品优先为隐性目标         |
| 自动化执行    | AI 输出必须包含可执行下一步，从建议到执行的闭环                   |
| 决策整合     | AI 亲子顾问是核心整合层，输出统一结构化决策方案                   |

1.3 AI 不做什么

- 不把用户消费简单判定为"对/错"，不做道德评判。
- 不直接替代家庭顾问、保险代理人、投资顾问或医生。
- 不在无授权情况下读取银行流水、儿童数据或保单信息。
- 不以"黑盒模型输出"作为最终用户提示，必须可解释、可复核。
- 不把规则生成的弱标签直接当作真值训练，必须经过抽检或人工复核。
- 不主动推销产品（MVP-V1.0）；仅在用户主动询问时以可选项形式展示

2 AI 不可替代性分析

结论：当前 AI Spec 把 AI 写成"高级聊天框"，用户确实可以复制账单去 ChatGPT 问。必须建立四个不可替代性壁垒。

2.1 四大壁垒 vs ChatGPT

| 壁垒 | 招贝 AI 能力 | ChatGPT 局限 | 不可替代性等级 |
|----|----------|------------|---------|
|----|----------|------------|---------|

| 壁垒     | 招贝 AI 能力                                 | ChatGPT 局限                | 不可替代性等级 |
|--------|------------------------------------------|---------------------------|---------|
| 私有数据壁垒 | 批量 OCR+银行 API+课程合<br>同结构化解析，自动关联家<br>庭画像 | 无法批量处理用户私有数<br>据，无法关联银行流水 | 极高      |
| 匿名基准壁垒 | 基于招行用户聚合数据："同<br>城市同收入家庭通常花多少"<br>用户聚合数据 | 只有通用网络知识，无银行              | 高       |
| 行动闭环壁垒 | 直接生成预算重分配草案、<br>触发招行定投计划、预约顾<br>问        | 只能给建议，无法执行任何<br>银行操作      | 极高      |
| 持续校准壁垒 | 基于用户纠错和忽略行为在<br>线调整个性化策略，越用越<br>准        | 无持续学习用户行为的能<br>力，每次对话独立   | 高       |

## 2.2 逐项对比分析

### 2.2.1 私有数据壁垒

招贝 AI 可以批量处理用户的 OCR 账单截图、银行 API 流水、课程合同，并自动将这些数据与家庭画像（孩子年龄、城市、收入区间、教育目标）关联。这种批量关联和结构化解析能力是 ChatGPT 无法做到的——用户不可能每次手动复制粘贴所有账单数据给 ChatGPT，更不可能授权 ChatGPT 读取银行账户。

技术实现：OCR 结构化抽取+商户映射+家庭画像关联+交易/OCR/银行 API 多源融合。

### 2.2.2 匿名基准壁垒

招贝 AI 可以基于招商银行用户聚合数据，告诉用户"同城市、同收入、同年龄段孩子的家庭通常花多少"。这种基于真实银行用户数据的匿名基准，比 ChatGPT 的通用网络知识更精准、更可信、更符合中国市场实际。

合规要求：k 匿名聚合，用户可选择不参与共享。样本量达到统计显著性后才展示分位数。

### 2.2.3 行动闭环壁垒

招贝 AI 不只给建议，而是直接生成可执行的决策方案：预算重分配草案（用户一键确认即可调整）、招行定投计划触发（用户授权后自动执行）、人工顾问预约（复杂决策自动兜底）。从"建议"到"执行"的闭环是 ChatGPT 无法实现的。

关键设计：所有自动化操作必须用户确认后执行，不可自动扣款或自动购买产品。

### 2.2.4 持续校准壁垒

招贝 AI 基于用户的纠错行为（"这不是焦虑消费"）、忽略行为（用户不看某类建议）、点击行为（用户对哪类建议感兴趣）在线调整个性化策略。使用时间越长，AI 越了解这个家庭的消费模式和决策偏好。ChatGPT 的每次对话是独立的，没有这种持续校准能力。

技术实现：用户反馈闭环+主动学习+个性化策略在线调整。详见第 11 章。

## 3 AI 任务拆解

### 3.1 核心整合层：AI 亲子财务顾问

AI 亲子财务顾问是所有任务的整合层，其输出格式从"文字回答"升级为"结构化决策方案"，包含以下要素：

| 决策方案要素 | 说明               | 示例                                 |
|--------|------------------|------------------------------------|
| 诊断结论   | 基于家庭画像和数据的当前状态判断 | "教育支出占家庭收入 35%，超过同城市同收入家庭的中位数 28%" |
| 风险信号   | 需要用户关注的具体信号及依据   | "14 天内同类高价辅导支出 2 次，可能存在考试焦虑驱动"     |

| 决策方案要素 | 说明                        | 示例                                     |
|--------|---------------------------|----------------------------------------|
| 行动建议   | 可执行的具体下一步（非泛泛建议）          | "建议先购买体验课而非长期课包；设置 4 周后的复盘提醒"          |
| 预算调整草案 | AI 生成的预算重分配方案（用户可一键确认或调整） | 将兴趣班预算从 5000 元/月调整为 3800 元/月，差额转入教育金储备 |
| 自动化选项  | 用户可授权 AI 直接执行的操作          | "开启每月 2000 元教育金定投"（需用户确认）              |
| 顾问兜底   | 超出 AI 能力范围的复杂决策           | "涉及保险配置调整，建议预约人工顾问复核"                  |

### 3.2 自动化执行用例

以下为 AI 从"建议"到"执行"的典型用例：

- 1.焦虑消费自动拦截：当 AI 识别到可能的焦虑消费信号（如考试后 72 小时内连续报班），自动标记并推送提醒，用户确认后自动将该笔支出归类为"待复盘"，并设置 4 周后的复盘提醒。
- 2.预算重分配：AI 根据家庭财务画像和支出分析，生成预算重分配草案（如减少兴趣班支出、增加教育金储备），用户一键确认后自动调整预算参数。
- 3.账户操作确认：用户授权后，AI 可以触发招行定投计划的创建/修改（如每月自动转入教育金账户），但所有操作需用户二次确认，AI 不直接操作资金。
- 4.顾问预约：当 AI 判断决策复杂度超出自身能力（如保险配置调整、大额资产配置），自动推荐预约人工顾问，并生成问题摘要供顾问参考。

### 3.3 任务分层架构

| 任务        | 输入                | 输出                  | 模型/系统责任        | 版本    |
|-----------|-------------------|---------------------|----------------|-------|
| 交易/OCR 解析 | 银行流水、支付截图、发票、课程合同 | 金额、商户、时间、用途、周期、孩子/课 | OCR、结构化抽取、商户映射 | MVP-β |

| 任务               | 输入          | 输出          | 模型/系统责任       | 版本     |
|------------------|-------------|-------------|---------------|--------|
|                  | 同、手动录入      | 程关联         |               |        |
| 育儿支出分类           | 商户名、商品名、OCR | 一级/二级/三级支出类 | 分类模型+商户词典+    | MVP-β  |
|                  | 文本、金额、时间、   | 目与置信度       | 规则            |        |
|                  | 孩子年龄、历史记录   |             |               |        |
| 消费性质判断           | 品类、金额、预算占   | 必要/成长/可能焦虑/ | 规则+小模型+阈值策    | MVP-β  |
|                  | 比、历史频率、家庭   | 风险/不确定      | 略             |        |
|                  | 画像          |             |               |        |
| 焦虑原因识别           | 购买动机、短期行    | 焦虑信号类型、等    | 多标签分类+规则引擎    | MVP-β  |
|                  | 为、同类重复、考试/  | 级、依据        |               |        |
|                  | 促销节点、孩子反馈   |             |               |        |
| 兴趣班 ROI 评估       | 课程价格、频率、通   | 课程价值分、风险    | 结构化评分模型+LLM   | V2.0   |
|                  | 勤、出勤、孩子反    | 分、组合优化建议    | 解释            |        |
|                  | 馈、目标、已有课程   |             |               |        |
| 教育金测算            | 孩子年龄、城市、路   | 总成本、缺口、月度   | 规则计算引擎+成本知    | MVP-α  |
|                  | 径、当前储备、每月   | 建议、阶段计划     | 识库            |        |
|                  | 可储备金额       |             |               |        |
| AI 亲子财务顾问（核心整合层） | 用户自然语言问题、   | 结构化决策方案（诊   | 意图识别+RAG+LLM+ | MVP-β  |
|                  | 家庭画像、历史支    | 断+风险+建议+预算草 | 护栏+方案整合       |        |
|                  | 出、知识库、所有任   | 案+自动化选项+顾问  |               |        |
| 自动化执行            | 用户确认的决策方案   | 预算调整、定投触    | 规则引擎+API 调用+确 | V1.0   |
|                  |             | 发、顾问预约      | 认流程           |        |
|                  |             |             |               |        |
| 反馈学习             | 用户确认/纠错、人工  | 训练样本、规则调    | 数据闭环与模型治理     | MVP-β起 |
|                  | 复核、线上指标     | 整、模型迭代      |               |        |
|                  |             |             |               |        |



## 4 数据来源与数据契约

### 4.1 数据来源分层

| 数据来源         | MVP/V 版本   | 关键字段                      | 主要用途             | 授权/风险         |
|--------------|------------|---------------------------|------------------|---------------|
| 用户主动输入       | MVP-α      | 孩子年龄、城市、收入区间、房贷、教育目标、已有保险 | 建家庭画像、初诊报告、教育金倒推 | 显性告知用途；允许区间输入 |
| 手动账单/课程录入    | MVP-α      | 课程名、价格、频率、孩子反馈、购买原因       | 兴趣班评估、焦虑原因识别     | 用户主动提供        |
| OCR/截图/发票/合同 | MVP-β      | 金额、商户、交易时间、项目名、课程周期       | 支出分类、课包风险、账单导入   | 上传即授权本次识别     |
| 招行账户 API     | V1.0 增强/试点 | 金额、商户名、交易类型、时间、账户维度       | 自动分类、预算分析、趋势分析   | 金融数据需单独授权     |
| 用户纠错反馈       | MVP-β起     | 原标签、用户修正标签、纠错原因           | 训练集建设、规则下线、主动学习  | 需在隐私政策说明用途    |
| 人工标注数据       | MVP-β起     | 类目、性质、焦虑原因、风险等级、置信度       | 训练支出分类和焦虑模型      | 标注平台需脱敏       |
| 匿名同阶段家庭参考    | V2.0       | 同城同龄聚合支出中位数/分位数           | 支出合理性参考          | k 匿名，用户可退出    |

## 5 标签体系与分类标准

### 5.1 支出品类标签

| 一级类目   | 二级/三级示例                |
|--------|------------------------|
| 基础生活   | 奶粉、尿布、童装、辅食、婴儿用品、儿童家具  |
| 教育/托育  | 幼儿园、托育、学费、课后服务、教辅资料    |
| 兴趣班    | 体育、美术、音乐、舞蹈、编程、语言、学科辅导 |
| 医疗健康   | 疫苗、门诊、儿童医院、药品、视力矫正     |
| 阅读与玩具  | 绘本、图书、益智玩具、电子设备        |
| 亲子娱乐   | 亲子游、研学、营地、儿童乐园         |
| 保险保障   | 医保、医疗险、重疾险、意外险、寿险      |
| 财商与零花钱 | 零花钱、压岁钱、储蓄目标           |
| 教育金储备  | 定投、存款、儿童账户             |

### 5.2 消费性质标签

| 标签    | 定义                | 判定依据                | 展示原则                |
|-------|-------------------|---------------------|---------------------|
| 必要型   | 满足基础照护、安全、健康、学校刚需 | 孩子年龄、基础生活/医疗/学费     | 直接展示为必要支出           |
| 成长型   | 对长期能力有明确帮助        | 目标匹配、孩子参与、出勤、预算可承受  | 展示对应成长目标            |
| 可能焦虑型 | 消费行为存在焦虑驱动信号      | 同伴比较、考试触发、促销课包、同类重复 | 使用"可能存在焦虑信号"，必须解释原因 |
| 风险型   | 金额大、周期长、退费不确定     | 长期课包、分期、退费规则不明、超预算  | 强调财务和履约风险           |
| 不确定   | 信息不足或模型置信度不足      | 缺少孩子反馈、目标、出勤        | 触发追问，不强行判断          |

## 6 训练数据建设方案

### 6.1 数据获取路径

| 阶段            | 目标样本          | 来源                                | 说明                 |
|---------------|---------------|-----------------------------------|--------------------|
| MVP- $\alpha$ | 500—1000 条    | 手动录入、历史样例、规则生成样本                  | 验证字段设计、类目体系、前端交互   |
| MVP- $\beta$  | 6000—10000 条  | 130 组种子用户（预计留存 90 组），每周 300—500 条 | 训练第一版支出分类模型和焦虑风险模型 |
| V1.0          | 20000—50000 条 | 用户纠错、OCR 样本、授权账户流水                | 模型微调 and 阈值校准      |
| V2.0          | 规模化持续样本       | 线上反馈、主动学习、A/B 测试                  | 专属小模型迭代和个性化优化      |

### 6.2 分层抽样测试集方案

支出分类准确率 $\geq 85\%$ 必须有分层抽样方案，确保模型在不同子群体上均有良好表现：

| 分层维度  | 分层标准                            | 测试集最低样本量           | 说明                  |
|-------|---------------------------------|--------------------|---------------------|
| 城市线级  | 一线/新一线/二线/三线及以下                 | 每层级 $\geq 100$ 条   | 一线城市消费结构差异大，需单独测试   |
| 收入区间  | <20 万/20 万—40 万/40 万—60 万/>60 万 | 每层级 $\geq 100$ 条   | 收入直接影响预算判断阈值        |
| 高敏场景  | 医疗/安全/基础教育刚需                    | 单独测试集 $\geq 200$ 条 | 这些场景宁可漏报不可乱报，误报代价极高 |
| 孩子年龄段 | 0-2 岁/3-5 岁/6-12 岁/13-18 岁      | 每层级 $\geq 100$ 条   | 不同年龄段支出模式差异显著       |
| 支出金额  | <500 元/500-2000 元/>2000         | 每层级 $\geq 100$ 条   | 高金额支出分类错误影响更        |

| 分层维度 | 分层标准 | 测试集最低样本量 | 说明 |
|------|------|----------|----|
|      | 元    |          | 大  |

## 7 模型架构与选型

### 7.1 总体架构

用户输入/OCR/银行 API/手动录入 → 数据清洗与标准化 → 商户识别与育儿消费 Taxonomy 匹配 → 支出品类分类模型 → 消费性质与焦虑风险模型 → 规则引擎校验与置信度策略 → 低置信/高风险 Case → LLM 复核或追问 → RAG 检索家庭画像/预算/政策/教育成本 → LLM 生成结构化决策方案 → 用户纠错 → 人工抽检 → 训练数据回流

### 7.2 模型分层

| 层级      | 用途                 | 推荐选型                       | 上线策略                |
|---------|--------------------|----------------------------|---------------------|
| 规则引擎    | 冷启动、强可解释、合规兜底      | 规则 DSL/决策表/阈值策略            | MVP-β上线；每条规则可单独关闭   |
| 商户与品类分类 | 高频交易/OCR 文本分类      | 商户词典+中文 Embedding+LightGBM | V1.0 训练专属分类模型       |
| 焦虑风险模型  | 多标签焦虑原因识别与风险评分     | XGBoost/LightGBM+结构化特征     | V1.0 灰度，低置信不展示强判断   |
| 教育金计算引擎 | 可解释的成本测算与目标倒推      | 规则计算+成本参数库                 | MVP-α上线；参数半年更新      |
| LLM     | 解释、追问、决策方案生成、个性化建议 | MVP 使用 API 调用；后续评估私有化      | 不作为最终分类唯一依据         |
| RAG 知识库 | 政策、教育成本、保险知识、产品边界  | 向量检索+结构化检索+来源管理            | MVP 建立 500—800 知识片段 |

## 8 微调与训练流程

MVP 与 V1 阶段的微调重点是支出分类模型、消费性质模型和焦虑风险模型，而不是直接微调通用 LLM。LLM 负责解释、追问和生成决策方案；分类决策由结构化模型、规则、置信度策略和用户反馈共同决定。

### 8.1 训练样本结构

|                         |                           |
|-------------------------|---------------------------|
| raw_text                | xx 少儿编程 Python 年课包 4800 元 |
| merchant                | xx 少儿编程                   |
| amount                  | 4800                      |
| child_age               | 8                         |
| city_tier               | 新一线                       |
| income_band             | 20 万—60 万                 |
| annual_education_budget | 30000                     |
| same_category_count_90d | 2                         |
| course_duration_months  | 12                        |
| attendance_rate         | 0.62                      |
| child_feedback          | neutral                   |
| purchase_reason         | peer_pressure             |
| label_category          | 兴趣班-科技                    |
| label_spending_type     | 风险型                       |
| label_anxiety_types     | [同伴比较驱动, 长期预付风险, 孩子参与度低]  |

### 8.2 置信度策略

| 场景            | 阈值策略     | 用户呈现          |
|---------------|----------|---------------|
| 分类置信度≥0.85    | 可自动分类    | 显示分类，可一键修改    |
| 0.65≤置信度<0.85 | 显示"建议分类" | 提示用户确认        |
| 分类置信度<0.65    | 不自动下结论   | 要求用户选择类目或补充信息 |

| 场景                    | 阈值策略           | 用户呈现         |
|-----------------------|----------------|--------------|
| 焦虑风险中高且 Precision 已验证 | 可提示可能焦虑信号      | 必须展示依据和纠错入口  |
| 医疗/安全/刚需高敏场景          | 除非证据充分，否则不提示焦虑 | 优先提示"建议人工复核" |

## 9 RAG 知识库与 AI 顾问

### 9.1 RAG 架构

用户问题 → 意图识别（20 类） → 个人数据检索（家庭画像、历史支出、教育金进度） → 知识库检索（育儿财务知识库/政策法规库/教育成本库/银行服务库） → LLM 生成结构化决策方案 → 安全/中立性校验 → 用户呈现：诊断+风险+建议+预算草案+自动化选项+顾问兜底+反馈入口

### 9.2 知识库建设

| 知识库     | 首版内容                        | 更新频率     | 展示要求                    |
|---------|-----------------------------|----------|-------------------------|
| 育儿财务知识库 | 用户画像、预算模板、课程<br>评估框架、保险基础知识 | 季度复核     | 回答应说明适用阶段和前提假设          |
| 教育成本库   | 国内本科、民办本科、国际<br>路线、留学成本参数   | 至少半年更新   | 教育金测算必须展示成本更新时间         |
| 政策法规库   | 税务、医保、儿童数据、金融<br>融建议边界      | 政策变更触发更新 | 涉及法规时只做说明               |
| 银行服务库   | 教育金账户、少儿账户、保<br>险/理财服务边界    | 由业务维护    | 必须经过中立性护栏； MVP 不直接做产品推荐 |
| 运营案例库   | 匿名化典型家庭案例、常见问题              | 月度更新     | 不得泄露用户身份或精确流水           |

9.3 AI 顾问回答规范（结构化决策方案格式）

- 回答必须包含五个要素：诊断结论、风险信号、行动建议、预算调整草案、下一步可执行操作。
- 每条建议至少包含：结论、依据、风险、下一步行动。
- 涉及金融服务时必须声明不构成投资建议；MVP 不输出具体买卖指令。
- AI 不得通过夸大焦虑诱导购买；禁止使用"再不报就晚了"等营销话术。

10 评估指标与上线门槛

10.1 离线评估

| 指标                | MVP 目标 | V1.0 目标 | 说明                    | 测试集要求            |
|-------------------|--------|---------|-----------------------|------------------|
| 支出分类<br>Accuracy  | ≥85%   | ≥88%    | 按人工标注测试集计算            | 分层抽样（城市/收入/高敏场景） |
| 焦虑识别<br>Precision | ≥80%   | ≥85%    | MVP 优先 Precision，减少误报 | 高敏场景单独测试集        |
| 焦虑识别 Recall       | ≥60%   | ≥70%    | 后续随数据积累提升             | 分层评估             |
| 高敏场景误报率           | <10%   | <5%     | 医疗、安全、基础教育刚需不能轻易标焦虑   | 独立测试集≥200 条      |
| 规则纠错率             | ≤25%   | ≤20%    | 超过阈值暂停该规则             | 线上监控             |
| 解释满意度             | ≥70%   | ≥80%    | 内测问卷/用户反馈             | 定性+定量            |
| 决策方案完成率           | ≥75%   | ≥85%    | 结构化决策方案五要素完整率         | 新增指标             |

10.2 在线监控

| 监控项          | 触发阈值       | 处理策略               |
|--------------|------------|--------------------|
| 单规则纠错率       | >25%持续 3 周 | 暂停规则，进入人工复核与规则重写   |
| 用户负反馈率       | >10%       | 检查文案是否冒犯，降低提示强度    |
| 低置信提示占比      | >40%       | 优化数据字段或触发追问        |
| LLM 幻觉/无依据回答 | 抽检发现严重问题   | 下线对应 Prompt 或知识库片段 |

| 监控项      | 触发阈值           | 处理策略              |
|----------|----------------|-------------------|
| 中立性异常    | 银行产品导向回答占比异常升高 | 触发合规/产品审查         |
| 自动化操作失败率 | >5%            | 检查 API 链路，降级为人工确认 |

## 11 反馈闭环与持续迭代

### 11.1 用户纠错闭环

AI 标注/提醒 → 用户查看依据与置信度 → 用户选择：准确/部分准确/不准确 → 用户选择纠错原因 → 样本进入反馈池 → 人工抽检与仲裁 → 加入训练集或规则修订 → 离线评估 + 灰度发布 → 监控纠错率、误报率、解释满意度

### 11.2 主动学习策略

- 优先抽检高金额、低置信、规则模型冲突、用户纠错频繁的样本。
- 将"模型不确定"视为有价值的训练样本，不隐藏不确定性。
- 每次模型重训前冻结测试集，避免测试集被污染。
- 按孩子年龄、城市、收入区间、品类分层评估，防止模型只对核心城市高收入家庭有效。
- 建立错误案例库，供产品文案、规则、模型、标注准则共同迭代。



## 12 安全、合规与中立性护栏

### 12.1 数据安全

| 要求   | 说明                          |
|------|-----------------------------|
| 最小必要 | 仅采集实现家庭财务规划所需字段             |
| 分级授权 | 手动输入、OCR 识别、账户 API、训练改进分别授权 |
| 可撤回  | 用户撤回授权后停止新增分析，提供历史记录导出和删除   |
| 脱敏标注 | 人工标注平台不得展示真实姓名、完整卡号、精确地址    |
| 日志审计 | 保留模型调用、提示生成、用户反馈、人工复核记录     |

### 12.2 中立性护栏

- MVP 阶段 AI 只输出规划分析，不直接推荐具体金融产品。
- V1/V2 如接入银行服务，必须先展示问题诊断、需求匹配和风险提示，再展示服务入口。
- AI 回答不得把招行产品作为默认最优解；必须说明适配条件和不适配条件。
- 每月进行中立性抽检，检查产品导向、恐惧营销、过度承诺和遗漏风险。

### 12.3 高敏场景处理

| 场景         | 处理策略                    |
|------------|-------------------------|
| 医疗/心理健康支出  | 不直接判断焦虑，提示预算影响并建议专业医疗意见 |
| 高额保险/理财    | 不输出买卖建议，进入规划分析和人工顾问复核   |
| 儿童自主消费异常   | 提醒家长沟通与规则设置，不做羞辱性描述     |
| 家庭冲突/教育压力  | 提供家庭会议卡片和预算沟通建议         |
| 低收入/预算紧张家庭 | 优先给低成本替代和安全线预警，不强化消费焦虑  |

## 13 版本路线图与开放问题

### 13.1 AI 路线图

| 阶段           | AI 能力                       | 数据/模型重点                    | 决策方案能力      |
|--------------|-----------------------------|----------------------------|-------------|
| MVP-α W1—W3  | 家庭画像、教育金计算、基础 AI 顾问 Prompt  | 定义字段、标签、成本参数、RAG 首版        | 基础诊断+建议     |
| MVP-β W4—W6  | OCR 导入、支出分类、5 类焦虑规则、结构化决策方案 | 规则引擎、商户词典、纠错入口、种子标注        | 完整五要素方案     |
| V1.0 W7—W10  | 分类模型灰度、反焦虑周报、保险基础知识、自动化执行   | 训练 6000—10000 样本，离线评估和灰度发布 | 方案+一键执行     |
| V2.0 W11—W18 | 兴趣班 ROI、同阶段参考、零花钱财商、专属小模型   | 多标签焦虑模型、主动学习、匿名参考数据        | 方案+自动化+顾问预约 |
| V3.0 W19—W26 | 高价值家庭资产协同、跨境教育金、私行顾问复核      | 高端知识库、人工顾问工作台、私有化评估        | 全自动化闭环      |

### 13.2 开放问题

- 焦虑识别标签是否需要教育心理学顾问参与定义，以降低主观性。
- 同阶段家庭参考数据达到多少样本量后才允许展示分位数。
- 账户 API 接入后，交易明细用于训练是否需要二次授权。
- 招行产品库在 AI 顾问中的呈现边界：只做服务入口，还是可以做方案匹配。
- 用户纠错数据是否可跨家庭用于模型训练，及相应隐私授权文案。
- 自动化执行的法律边界：AI 触发银行操作的用户授权合规性确认。

感谢阅读

招商银行 | 招贝产品 | 2026 年 5 月